Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №2

«Методы построения моделей машинного обучения»

Вариант № 21

 Выполнил:
 Проверил:

 Фролов М. К.
 Гапанюк Ю.Е.

 группа ИУ5-64Б

Дата: 12.06.25 Дата:

Подпись: Подпись:

Задание:

Для заданного набора данных https://www.kaggle.com/datasets/oreojam/formula-e-world-championship-race-results постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы Линейная/логистическая регрессия и Градиентный бустинг. Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Ход выполнения:

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline

from sklearn.linear_model import LogisticRegression, LinearRegression
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor

from sklearn.metrics import (
    accuracy_score, roc_auc_score, precision_score, recall_score, f1_score,
    mean_squared_error, mean_absolute_error, r2_score
)
```

```
def time to seconds(t):
   if pd.isna(t):
       return np.nan
   parts = t.split(':')
   try:
       if len(parts) == 2:
           minutes, seconds = parts
           return int(minutes) * 60 + float(seconds)
       elif len(parts) == 3:
           hours, minutes, seconds = parts
           return int(hours) * 3600 + int(minutes) * 60 + float(seconds)
       else:
           return float(t)
   except:
       return np.nan
df = pd.read csv('Formual E Raceresults.csv')
for col in ['Best', 'Started', 'Time']:
     df[f'{col} sec'] = df[col].apply(time to seconds)
df['SeasonYear'] = (
     df['SeasonName']
       .str.extract(r'(\d{4})', expand=False)
       .astype(float)
df = df[df['SeasonYear'].notna()].copy()
df['SeasonYear'] = df['SeasonYear'].astype(int)
df['Driver'] = df['DriverFirstName'] + ' ' + df['DriverLastName']
df['podium'] = (df['Pos'] <= 3).astype(int)</pre>
features = [
     'SeasonYear',
     'Team',
     'DriverNumber',
     'Driver',
     'Best sec',
     'Started_sec',
     'Time sec'
```

Классификация "подиум/не-подиум"

```
X_clf = df[features]
y_clf = df['podium']
X_train_c, X_test_c, y_train_c, y_test_c = train_test_split(
   X_clf, y_clf,
   test size=0.2,
    stratify=y_clf,
    random state=42
pipe_lr_clf = Pipeline([
   ('prep', preprocessor),
    ('scale', StandardScaler(with_mean=False)),
    ('clf', LogisticRegression(max_iter=1000))
1)
pipe_gb_clf = Pipeline([
   ('prep', preprocessor),
    ('clf', GradientBoostingClassifier(n_estimators=200, random_state=42))
1)
pipe_lr_clf.fit(X_train_c, y_train_c)
pipe_gb_clf.fit(X_train_c, y_train_c)
y_pred_lr = pipe_lr_clf.predict(X_test_c)
y_proba_lr = pipe_lr_clf.predict_proba(X_test_c)[:,1]
y_pred_gb = pipe_gb_clf.predict(X_test_c)
y_proba_gb = pipe_gb_clf.predict_proba(X_test_c)[:,1]
```

```
metrics_clf = pd.DataFrame({
    'Model': ['LogisticRegression', 'GradientBoosting'],
    'Accuracy': [
        accuracy_score(y_test_c, y_pred_lr),
        accuracy_score(y_test_c, y_pred_gb)
    ],
    'ROC AUC': [
       roc_auc_score(y_test_c, y_proba_lr),
        roc_auc_score(y_test_c, y_proba_gb)
    ],
    'Precision': [
        precision_score(y_test_c, y_pred_lr),
        precision_score(y_test_c, y_pred_gb)
    'Recall': [
        recall_score(y_test_c, y_pred_lr),
        recall_score(y_test_c, y_pred_gb)
    ],
    'F1-score': [
       f1_score(y_test_c, y_pred_lr),
       f1_score(y_test_c, y_pred_gb)
}).set_index('Model')
print("Classification metrics:\n", metrics_clf)
```

```
Accuracy ROC AUC Precision Recall F1-score Model
LogisticRegression 0.657807 0.645965 0.475610 0.393939 0.430939
GradientBoosting 0.727575 0.720672 0.630769 0.414141 0.500000
```

```
X_reg = df[features]
y_reg = df['Pos']
X_train_r, X_test_r, y_train_r, y_test_r = train_test_split(
   X_reg, y_reg, test_size=0.2, random_state=42
pipe lr reg = Pipeline([
   ('prep', preprocessor),
    ('scale', StandardScaler(with_mean=False)),
   ('reg', LinearRegression())
1)
pipe_gb_reg = Pipeline([
   ('prep', preprocessor),
    ('reg', GradientBoostingRegressor(n_estimators=200, random_state=42))
])
pipe_lr_reg.fit(X_train_r, y_train_r)
pipe_gb_reg.fit(X_train_r, y_train_r)
y_pred_lr_r = pipe_lr_reg.predict(X_test_r)
y_pred_gb_r = pipe_gb_reg.predict(X_test_r)
rmse_lr = np.sqrt(mean_squared_error(y_test_r, y_pred_lr_r))
rmse_gb = np.sqrt(mean_squared_error(y_test_r, y_pred_gb_r))
```

```
X_reg = df[features]
y_reg = df['Pos']
X_train_r, X_test_r, y_train_r, y_test_r = train_test_split(
   X_reg, y_reg, test_size=0.2, random_state=42
pipe_lr_reg = Pipeline([
    ('prep', preprocessor),
    ('scale', StandardScaler(with_mean=False)),
    ('reg', LinearRegression())
1)
pipe_gb_reg = Pipeline([
    ('prep', preprocessor),
    ('reg', GradientBoostingRegressor(n_estimators=200, random_state=42))
])
pipe_lr_reg.fit(X_train_r, y_train_r)
pipe_gb_reg.fit(X_train_r, y_train_r)
y_pred_lr_r = pipe_lr_reg.predict(X_test_r)
y_pred_gb_r = pipe_gb_reg.predict(X_test_r)
rmse_lr = np.sqrt(mean_squared_error(y_test_r, y_pred_lr_r))
rmse_gb = np.sqrt(mean_squared_error(y_test_r, y_pred_gb_r))
```

Regression metrics:

RMSE MAE R2

Model

LinearRegression 6.129629 4.929065 -0.082406 GradientBoosting 5.778500 4.637041 0.038050